資料工程 HW0

404410030 資工四 鄭光宇

系統需求

要執行這支程式,系統必須具備:

- 支援 ANSI C 的 gcc
- make 指令

如何編譯

在專案目錄下輸入指令:

make

如何執行

同作業要求

rsort 檔名 [參數]

peter@peter-desktop:~/Data-Engineering/HW1\$./rsort
Usage:
rsort filename [-d delimeter | -k field | -n numeric comparison | -r reverse sort | -c case insensitive]
peter@peter-desktop:~/Data-Engineering/HW1\$

- -d 是分隔符號,-k 是要作為 key 的 pattern
- 而 -c 是不區分大小寫、-n 使用數值排序、-r 倒序(降序)排序

實作部分

前置處理

先合併檔

ıta\$ cat ettoday0.rec ettoday1.rec ettoday2.rec ettoday3.rec ettoday4.rec ettoday5.rec > fullfile.rec ıta\$ █

主函數部份

讀取執行參數、讀檔、斷行、排序、輸出

```
int main(const int argc, const char **argv) {
    int i=0;
    int i=0;
    int i=0;
    int records = NULL;
    char **records = NULL;
    int records_cnt = 0;
    if (argc<2) {
        fprint(stderr, "Usage:\nrsort filename [-d delimeter | -k field | -n numeric comparison | -r reverse sort | -c case insensitive]\n");
    int records_cnt = (argv, parameters, set_parameters);
    int records_cnt = reader(argv[1], &records); /* need to free! */
    int records_cnt = reader(argv[1], &records); /* need to free! */
    int records_cnt = reader(argv[1], &records_cnt, sizeof(char*), comp);
    int records_cnt = reader(argv[1], argcords_cn
```

讀檔部份跟前一次作業類似,就不放上來了

讀取參數部份

```
1 rsort.c
  1 #include <stdio.h>
 2 #include <stdlib.h>
 3 #include <string.h>
 4 #include <ctype.h>
 9 };
10 const char *parameters[2]; /* -d, -k */
11 int set_parameters[3]={0}; /* -c, -r, -n */
12
   int parse_parameter(const int argc, const char** args, const char* pattern) {
13
        int i=0;
14
        for (i=0; i< argc; ++i) {
            if(strstr(args[i], pattern)!=NULL) return i;
        return -1;
20
   void get_args(const int argc, const char** args, const char **parameters, int *set_parameters) {
    /** parse all parameters in following order
21
22
         * -d record_delimiter
23
         * -k key_pat
24
         * -c case_insensitive
         * -r reverse order
26
27
         * -n numerical comparison
28
        int i = 0, argspos=-1;
29
        for (i=0; i<2; ++i) {
30
            argspos = parse_parameter(argc, args, parameter_patterns[i]);
            parameters[i] = argspos<0?default_args[i]:args[argspos+1];</pre>
        for (i=0; i<3; ++i) {
34
            set_parameters[i] = parse_parameter(argc, args, parameter_patterns[i+2])<0?0:1;</pre>
36
 37
```

簡單解析從 main function 傳入的 argv 裏面的參數

-d, -k 後方需要接一個字串,其他3個參數則不需要輸入內容

排序用的比較函數

```
39 int comp(const void *a, const void *b) {
40
       int e=0, f=0;
       const char *c = *(const char**)a;
41
       const char *d = *(const char**)b;
42
43
       int val = 0;
       if (parameters[1][0]!='\0') { /* has field */
    /* not robust enough. need to handle more exceptions */
44
45
            c = strstr(c, parameters[1]); /* jump to that field */
46
47
            d = strstr(d, parameters[1]); /* ,, */
48
       }
if (set_parameters[2]) { /* numerical comparison? */
49
50
            while(c!=NULL&&*c!='\0'&&!isdigit(*c)) ++c;
51
            while(d!=NULL&&*d!='\0'&&!isdigit(*d)) ++d;
52
            e = atoi(c);
            f = atoi(d);
53
54
            val = e-f;
       } else { /* lexical order */
56
            val = set_parameters[0]?strcasecmp(c,d):strcmp(c,d); /* case insensitive? */
57
58
       return set_parameters[1]?-val:val; /* reverse order? */
59
```

同作業要求,實作了依照-k為key值排序、依照-n 決定是否為數值排序、依照-c 決定是否區分大小寫、依照-r 決定是否降序排序。

實驗

使用上次作業的資料集的合併檔

照文章標題排序

```
peter@peter-desktop:~/Data-Engineering/HW1$
```

花費時間約為18秒

照URL中的編號排序

升序

降序

其他實驗

數字排序

```
peter@peter-desktop:~/Data-Engineering/HW1$ cat 123
222 111 333 6 7 3333 44 444 55
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort 123 -d " "
111 222 333 3333 44 444 55 6 7
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort 123 -d " " -n
6 7 44 55 111 222 333 444 3333
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort 123 -d " " -n -r
3333 444 333 222 111 55 44 7 6
peter@peter-desktop:~/Data-Engineering/HW1$
```

大小寫字母排序

```
peter@peter-desktop:~/Data-Engineering/HW1$ cat abc
a b c d e f g A B C D E F G
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort abc -d " "
A B C D E F G a b c d e f g
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort abc -d " " -r
    g f e d c b a G F E D C B A
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort abc -d " " -c
    a A b B c C d D e E f F g G
peter@peter-desktop:~/Data-Engineering/HW1$ ./rsort abc -d " " -c -r
    g G f F e E d D c C b B a A
peter@peter-desktop:~/Data-Engineering/HW1$
```

總結

程式行為符合預期,如果是針對數字就必須使用數值排序。

不然預設就是字典序,這點可以從 3333 44 444 55 和 7 44 55 111 ... 3333 兩種排序看出來。 -n 這個選項是方便的功能。

GitHub

https://github.com/peter0749/Data-Engineering/tree/master/HW1